

임상 표현형에 따른 흉부 X-ray 의 ICU 전실 예측 추가 가치 분석

*Does the Incremental Value of Chest Radiographs for ICU Transfer Prediction
Differ Across Data-Driven Clinical Phenotypes?*

연구계획서 초안

TEAM_03 | 문헌 탐색 기준일: 2026-07-23

0. 요약 및 선행연구 탐색 후 novelty 재평가

본 연구는 임상정보만으로 도출한 data-driven phenotype 별로, 임상정보 단독 모델 대비 흉부 X-ray(CXR) 특징을 추가한 멀티모달 모델의 초기 ICU 전실 예측 성능이 얼마나 달라지는지를 평가한다. 핵심 질문은 “CXR를 넣으면 평균 성능이 좋아지는가?”가 아니라 “어떤 임상적 환자 유형에서 CXR가 추가적인 예측 정보를 제공하는가?”이다.

항목	평가
Novelty	중간-중상: 멀티모달 CXR+임상 예측 자체는 이미 다수 보고되었으나, 임상정보 기반 비지도 phenotype 별 incremental value의 이질성을 평가하는 정확히 동일한 설계는 본 표적 탐색에서 확인하지 못함.
Feasibility	중간: 모델 자체는 frozen RAD-DINO feature + 표형 모델로 구현 가능하나, 군집별 test 사건 수 부족이 가장 큰 위험.
정확한 포지셔닝	“세계 최초”가 아니라, 기존 평균 성능 비교를 환자군별 효용 이질성(heterogeneity of incremental value)으로 확장하는 탐색적 연구.

문헌 탐색상, EHR 기반 초기 악화·ICU 전실 예측은 활발하며, 임상 데이터와 CXR를 결합한 사망·중증도 예측도 이미 보고되었다. 예를 들어 Lin 등은 MIMIC-IV 및 외부 병원 자료로 임상변수와 CXR를 융합한 30일 ICU 사망 예측 모델을 개발했고, 외부 test에서 임상 단독보다 높은 AUC를 보고했다[5]. Cheng 등과 Li 등도 특정 질환 코호트에서 longitudinal CXR와 임상자료의 결합 효과를 보고했다[6,7]. 따라서 “멀티모달이 단일모달보다 낫다”만으로는 novelty가 낮다. 반면 EHR 군집분석을 이용한 data-driven phenotyping은 응급실 자료 등에서 임상적으로 구별되는 환자군을 탐색하는 방법으로 사용되어 왔으나[8], 그 phenotype 별로 CXR의 incremental value를 비교하는 설계는 표적 검색에서 직접 확인되지 않았다. 이 부재는 체계적 문헌고찰로 증명된 것이 아니므로, ‘미보고’가 아니라 ‘본 탐색에서 직접 선행연구를 찾지 못했다’고 표현한다.

1. Background / Introduction

일반병동 및 응급실 환자의 예기치 않은 악화를 조기에 인지하고 적절한 수준의 치료로 escalation 하는 것은 환자 안전과 제한된 ICU 자원 배분에 중요하다. ICU 전실 지연은 불량한 결과와 연관된다는 보고가 있으며, 이러한 이유로 NEWS, MEWS와 같은 초기경보점수와 EHR 기반 머신러닝 모델이 개발되어 왔다[1,2]. 최근 7개 병원의 36만 건 이상 입원 사례를 비교한 연구에서는 EHR 기반 eCART가 여러 기존 및 상용 초기경보점수보다 높은 판별력을 보였지만, 양성예측도와 경보 효율은 모델별로 크게 달랐다[2]. 한국의 다기관 전향적 연구에서도 DeepCARS가 24시간 내 병동 심정지 또는 비계획 ICU 전실을 NEWS와 MEWS보다 정확하게 예측했다[3].

기존 초기악화 모델의 입력은 주로 연령, 활력징후, 검사실 수치, 의식상태, 산소 요구량과 같은 구조화 EHR 정보이다[1-4]. 그러나 CXR는 응급실과 병동에서 흔히 시행되며 폐렴, 폐부종, 무기폐, 흉막삼출, 심비대 등 호흡·순환기 상태의 시각적 단서를 포함한다. 최근 멀티모달 연구는 CXR가 구조화 임상정보에 추가적인 예측 신호를 제공할 가능성을 보여주었다. Lin 등의 PrismICU 연구에서는 임상자료와 CXR를 결합한 모델이 임상 단독 및 영상 단독 모델보다 30일 ICU 사망 예측 성능이 높았다[5]. COVID-19 ICU 환자 연구에서도 longitudinal CXR를 임상자료에 추가했을 때 사망 예측 AUC가 유의하게 개선되었고[6], 심부전 환자에서도 longitudinal CXR와 EHR를 결합한 모델이 임상자료 단독보다 높은 성능을 보였다[7].

본 연구에서는 CXR 전체를 end-to-end로 재학습하기보다 RAD-DINO를 frozen image encoder로 사용한다. RAD-DINO는 영상-텍스트 쌍이 아닌 대규모 흉부영상 자체를 이용한 자기지도학습 인코더로, 다양한 downstream 영상 과제에서 경쟁력 있는 표현을 제공하도록 개발되었다[9]. 소규모 교육 프로젝트에서는 frozen feature를 사용함으로써 전체 가중치 fine-tuning에 따른 과적합과 계산 부담을 줄일 수 있다.

2. Research Gap

현재 확인된 선행연구의 공통점은 다음과 같다.

- EHR 기반 ICU 전실·임상악화 예측은 주로 전체 모집단에서의 AUROC, AUPRC 또는 경보 효율을 평가한다[1-4].

- CXR+영상 멀티모달 연구는 주로 ICU 사망, COVID-19 예후 또는 심부전 사망처럼 특정 outcome·질환에서 전체 평균 성능 향상을 평가한다[5-7].
- Data-driven phenotyping 연구는 임상자료의 잠재적 환자군을 발견하고 시각화·예후 차이를 설명하지만, 영상 modality의 추가 가치가 phenotype 별로 달라지는지를 직접적인 주 질문으로 삼지는 않았다[8].

따라서 남는 질문은 “CXR가 전체 환자에서 평균적으로 도움이 되는가?”가 아니라 “동일한 CXR 정보라도 어떤 임상 phenotype에서 더 큰 추가 가치를 보이는가?”이다. 평균 AUC가 소폭 향상되더라도 그 개선이 특정 환자군에 집중될 수 있으며, 반대로 일부 phenotype에서는 임상정보만으로 충분해 영상 feature의 추가 이득이 거의 없을 수 있다. 이러한 성능 향상의 이질성을 규명하면 멀티모달 AI의 선택적 적용, 모델 모니터링, 외부검증 전략을 더 구체화할 수 있다.

3. Research Questions and Hypotheses

3.1 Primary research question

초기 임상정보만으로 도출한 data-driven clinical phenotype에 따라 CXR-derived feature가 48시간 내 ICU 전실 예측에 제공하는 incremental value가 달라지는가?

3.2 Secondary questions

1. 임상정보 기반 phenotype은 서로 다른 기저 위험도와 임상적 특성을 보이는가?
2. 전체 test set에서 Clinical+CXR 모델은 Clinical-only 모델보다 판별력, 정밀도-재현율 및 calibration이 개선되는가?
3. 어떤 phenotype에서 두 모델의 성능 차이가 가장 크며, 그 차이는 bootstrap 신뢰구간상 안정적인가?
4. 성능 차이는 CXR 촬영 자세(AP/PA), 기저 폐질환, 결측 패턴 또는 사건률 차이로 설명되는가?

3.3 Hypotheses

- H1: CXR의 추가 가치는 모든 phenotype에서 동일하지 않을 것이다.
- H2: 임상정보만으로 위험 구분이 불충분한 특정 phenotype에서 CXR feature 추가 시 AUPRC 및 AUROC가 더 크게 개선될 것이다.
- H3: 전체 평균 성능 향상보다 phenotype 별 향상 폭의 이질성이 더 임상적으로 유용한 정보를 제공할 것이다.

4. Data and Methodology

4.1 Study design and data source

MIMIC-IV-CXR와 연결 가능한 OMOP CDM 기반 후향적 코호트 연구로 설계한다. 데이터 접근환경에서 실제 이용 가능한 컬럼을 먼저 확인한 후 최종 변수와 outcome 정의를 고정한다. 분석 단위는 환자별 첫 적격 입원 또는 첫 적격 CXR로 하여 환자 중복에 따른 누수를 방지한다.

4.2 Index time and target outcome

Index time은 일반병동 또는 응급실에서 촬영한 첫 적격 CXR의 촬영 시각으로 정의한다. Primary outcome은 index CXR 이후 48시간 이내 비계획 ICU 전실이다. 촬영 시 이미 ICU에 있는 환자는 제외한다. ICU 전실 시각을 visit_detail 등에서 신뢰성 있게 확인할 수 없는 경우에는 사전에 정한 fallback outcome(예: 48시간 내 invasive mechanical ventilation 또는 7일 내 ICU 전실)을 사용하며, outcome 변경은 분석 전에 문서화한다.

4.3 Inclusion and exclusion criteria

- 포함: 만 18세 이상, 적격 입원/응급실 방문, index CXR 및 임상정보 연결 가능, outcome 관찰 가능.
- 제외: index 시점 ICU 입실 중, CXR 촬영시간 또는 ICU 전실시간 불명확, 환자 연결키 불일치, 영상 품질/경로 오류.
- 한 환자에 여러 적격 episode가 있으면 첫 episode만 사용하거나, episode를 사용할 경우 환자 단위 group split을 엄격히 적용.

4.4 Candidate clinical variables

변수는 선행연구에서 반복적으로 사용되고, index 시점 이전에 측정 가능하며, 데이터에서 충분한 가용성을 보이는 항목으로 제한한다[1-4]. 최종 선택은 데이터 dictionary 및 결측률 확인 후 확정한다.

영역	후보 변수	원칙
인구학	나이, 성별	CXR 촬영 전 고정 정보
활력징후	SBP/DBP, HR, RR, 체온, SpO ₂	index 전 6 시간 내 최근값 또는 요약값
검사실	WBC, Hb, platelet, creatinine, BUN, Na, K, bicarbonate, lactate 등	문헌·가용성·결측률을 기준으로 제한
기저질환	HF, COPD, CKD, cancer, diabetes 등	index 이전 진단만 사용
진료 맥락	ED/ward, oxygen support, 촬영 자세 AP/PA	shortcut/confounding 민감도 분석용

4.5 Data split and leakage prevention

환자 단위로 Train/Validation/Test 를 분리한다(예: 70/15/15 또는 제공된 공식 patient-level split 활용). 결측치 대체값, 표준화 평균·표준편차, feature selection, 군집 중심, 모델 hyperparameter 는 Train 에서만 학습한다. Validation 은 군집 수와 모델 설정 선택에 사용하며, Test 는 최종 평가에서 한 번만 사용한다. RAD-DINO 가 MIMIC-CXR 를 사전 학습에 포함했다는 점은 엄밀한 ‘완전한 외부 미노출’ test 가 아님을 인정해야 한다. 따라서 공식 MIMIC split 을 따르고, backbone 을 frozen 으로 유지하며, 본 결과를 독립 외부검증으로 표현하지 않는다.

4.6 Clinical phenotype discovery

- Train set 의 임상 변수만 사용한다. CXR feature, ICU outcome 및 index 이후 정보는 군집 생성에 사용하지 않는다.
- 연속형 변수는 Train 통계로 표준화하고, 결측치는 Train 의 중앙값 등으로 대체하며 missing indicator 를 별도 검토한다.
- 변수 수가 많거나 상관성이 높으면 PCA 를 적용하되, 해석 가능성을 위해 원변수 기반 K-means 를 1 차 분석으로 권장한다.
- 군집 수 K=2-4 를 후보로 두고 silhouette score, cluster size, bootstrap 안정성, 임상적 해석 가능성을 종합하여 선택한다.
- Validation/Test 환자는 Train 에서 산출된 centroid 중 표준화 유클리드 거리가 가장 가까운 군집에 배정한다.
- 군집의 이름은 결과를 과도하게 단정하지 않고 “저산소-염증형”, “고령-신기능저하형”처럼 주요 특징을 요약하는 기술적 명칭으로 사후 부여한다.

4.7 CXR representation

각 index CXR 는 RAD-DINO frozen backbone 으로 feature vector 를 추출한다[9]. 원본 feature 차원이 표본 수에 비해 지나치게 크면 Train 에서 PCA 또는 정규화된 linear projection 으로 차원을 축소한다. Test 를 포함한 전체 데이터로 PCA 를 fit 하지 않는다. Full fine-tuning 은 수행하지 않으며, 필요 시 linear/MLP probe 또는 표형 모델과의 late fusion 을 사용한다.

4.8 Prediction models

모델	입력	권장 알고리즘	역할
Model A	Clinical variables only	Logistic regression + Random Forest/XGBoost 중 1 개	기준 임상모델
Model B	동일 clinical variables + CXR feature	Model A 와 가능한 한 동일한 classifier	CXR incremental value 평가
선택 Model C	CXR feature only	Logistic/MLP probe	영상 단독 정보의 참고치

Model A와 B는 동일한 환자, 동일한 임상변수, 동일한 outcome 및 동일한 data split을 사용해야 한다. 차이는 CXR feature의 포함 여부뿐이어야 한다. 교육 프로젝트에서는 logistic regression을 투명한 baseline으로 두고 Random Forest 또는 XGBoost 하나를 추가하는 정도가 적절하다.

4.9 Evaluation and statistical analysis

- Primary metric: AUPRC. ICU 전실이 불균형 outcome 일 가능성이 높기 때문이다.
- Secondary metrics: AUROC, sensitivity, specificity, PPV, NPV, Brier score, calibration plot.
- 전체 Test에서 Model B - Model A의 Δ AUPRC 및 Δ AUROC를 paired bootstrap으로 95% CI 산출.
- 각 phenotype에서 같은 지표를 반복하고 모든 군집 결과를 누락 없이 제시.
- “한 군집에서 유의하고 다른 군집에서 비유의”만으로 군집 간 차이를 주장하지 않는다. 가능하면 phenotype $\times$ CXR-added interaction 또는 bootstrap 차이의 차이를 탐색적으로 평가.
- 군집별 사건 수가 적으면 점추정치보다 신뢰구간을 강조하고, 결론을 탐색적(exploratory)으로 제한.
- Calibration과 DCA는 사건 수가 충분한 경우 수행. DCA는 임상적으로 해석 가능한 threshold 범위를 사전에 정한다.

4.10 Sensitivity and robustness analyses

- K=2,3,4에서 phenotype 별 결과 방향이 유지되는지 확인.
- K-means 외 hierarchical clustering 또는 Gaussian mixture model을 보조분석으로 비교.
- 동일 AP/PA 촬영군 또는 AP/PA를 공변량으로 조정하여 촬영 방식 shortcut 가능성 확인.
- 폐질환 진단 유무를 사전 subgroup으로 사용하지 않고, 사후 군집 특성표에서만 기술.
- CXR feature 차원 축소 방식(PCA 차원 수)에 따른 결과 안정성 확인.
- 48시간 outcome이 너무 적으면 72시간 또는 7일을 secondary outcome으로 제시하되, 분석 후 임의 변경하지 않음.

5. Expected Results, Interpretation, and Clinical Significance

5.1 Plausible result scenarios

결과	해석	허용되는 결론
일부 phenotype에서만 큰 개선	CXR의 추가 예측정보가 임상 상태에 따라 이질적	해당 phenotype에서 CXR 기반 예측모델의 우선적 적용 가능성
모든 phenotype에서 비슷한 개선	영상정보가 넓은 환자군에 일관된 추가정보 제공	선택적 적용보다 광범위한 활용을 지지
전체·모든 phenotype에서 개선 없음	임상정보가 대부분의 예측신호를 이미 포함하거나 표본/feature 한계	CXR의 ICU 전실 예측 추가 가치가 제한적
군집별 추정치가 불안정	test 사건 수 부족 또는 군집 재현성 부족	결론 유보, 더 큰 코호트에서 검증 필요

5.2 Significance and expected impact

- 평균 성능 비교를 넘어, 멀티모달 정보의 효용이 환자군별로 어떻게 달라지는지 제시한다.
- 임상적으로 해석 가능한 phenotype을 통해 “누구에게 영상 AI가 추가로 유용한가”라는 질문에 접근한다.
- 향후 외부검증 시 단일 전체 성능뿐 아니라 phenotype 별 transportability와 calibration을 점검해야 한다는 근거를 제공한다.
- 이미 촬영된 CXR를 활용하는 예측 AI의 선택적 적용 가능성을 제시하되, CXR 검사 자체의 시행 여부나 비용효과를 직접 결론내리지 않는다.

6. Anticipated Critiques and Responses

Q1. “군집분석도 연구자 선택이 많은데 임의성을 배제했다고 할 수 있나?”

Response: 배제했다고 주장하지 않는다. 단일 cutoff나 사전 질환군 선택의 자의성을 줄이고 다변량 구조를 반영한다는 수준으로 표현한다. 변수 목록, K 선택 규칙, 전처리와 안정성 분석을 사전에 고정한다.

Q2. “K-means 는 데이터가 연속적이어도 억지로 군집을 만든다.”

Response: 맞다. silhouette, cluster size, bootstrap stability 와 임상적 해석 가능성을 모두 충족하지 못하면 phenotype 이라는 표현을 약화하고 단순 data-driven strata 로 보고한다.

Q3. “임상 변수로 군집을 만들고 같은 임상 변수로 Model A 를 평가하면 circular 하지 않나?”

Response: 군집은 예측모델 입력이 아니라 효과 이질성을 평가하는 층화 변수다. 질문 자체가 임상상태로 구분된 환자군에서 CXR 의 추가 가치가 다른지이므로 임상변수 기반 군집이 목적에 부합한다. 다만 해석은 ‘일반적 CXR 가치’가 아닌 ‘임상모델 대비 추가 가치’로 제한한다.

Q4. “왜 CXR feature 로 군집화하지 않았나?”

Response: 영상으로 환자군을 정의한 뒤 그 군집에서 영상 추가 효과를 평가하면 질문과 분류 기준이 동일 modality 에 의존해 순환적 해석 위험이 커진다. 따라서 군집은 영상과 outcome 을 배제한 임상정보만 사용한다.

Q5. “Test 를 군집분석에 사용하지 않으면 Test 의 자연 군집을 놓치는 것 아닌가?”

Response: Test 는 독립 검증 자료다. Train 에서 phenotype 정의를 고정하고 새 환자를 배정해야 재현성과 향후 적용 가능성을 평가할 수 있다. Test 에서 새 군집을 찾는 분석은 별도 탐색분석으로만 가능하다.

Q6. “군집별 test 사건 수가 너무 적을 수 있다.”

Response: 가장 중요한 실현가능성 위험이다. 분석 전에 event count 를 확인하고 K 를 2-3 으로 제한한다. paired bootstrap CI 를 제시하고, 사건 수가 부족하면 phenotype 별 분석을 exploratory 로 낮추거나 반복 교차검증 기반 내부검증으로 보조한다.

Q7. “Model B 가 더 많은 정보를 받으니 더 좋아지는 것은 당연하지 않나?”

Response: 추가 정보가 중복·노이즈이거나 표본이 작으면 성능이 개선되지 않거나 악화될 수 있다. 핵심 결과는 평균 개선 여부가 아니라 개선 폭이 phenotype 별로 이질적인지이다.

Q8. “이 결과로 특정 환자에게 CXR 을 찍지 않아도 된다고 말할 수 있나?”

Response: 불가능하다. 코호트는 이미 CXR 를 촬영한 환자만 포함하므로 검사 필요성·비용효과를 평가할 수 없다. 결론은 오직 CXR-derived feature 의 ICU 전실 예측 추가 가치에 한정한다.

Q9. “ICU 전실은 병원 bed availability 와 의사 결정에 좌우되는 불완전 outcome 이다.”

Response: 맞다. ICU 전실은 순수 생리적 악화뿐 아니라 시스템 요인의 영향을 받는다. 가능하면 mechanical ventilation/death 등 secondary outcome 을 함께 제시하고, 결과를 임상 악화의 대리 outcome 으로 해석한다.

Q10. “RAD-DINO 는 MIMIC-CXR 로 사전학습했으므로 leakage 아닌가?”

Response: backbone 이 MIMIC-CXR 를 포함한 데이터로 자기지도 사전학습된 것은 엄밀한 독립 test 의 한계다. 공식 patient split 을 준수하고 frozen backbone 만 사용해 downstream label leakage 를 줄이지만, 본 연구 결과를 MIMIC 과 독립된 외부검증으로 부르지 않는다. 가장 강한 검증은 별도 병원 코호트다.

Q11. “군집 이름을 보고 결과에 맞게 사후 스토리를 붙인 것 아닌가?”

Response: 모든 군집의 표준화 변수 프로파일과 outcome 을 투명하게 제시하고, 명칭은 기술적 요약에 그친다. 군집 별 효과 분석 계획과 primary metric 을 사전에 고정해 cherry-picking 을 줄인다.

7. Practical Go/No-Go Checklist

점검 항목	질문	판정
ICU transfer timestamp	visit_detail 등으로 index 이후 48 시간 outcome 을 정확히 만들 수 있는가?	☐ Go ☐ 수정 ☐ No-Go
사건 수	전체 및 예상 군집별 ICU transfer 사건이 충분한가?	☐ Go ☐ 수정 ☐ No-Go
임상변수 가용성	핵심 vital/lab 의 결측률이 허용 가능한가?	☐ Go ☐ 수정 ☐ No-Go
영상 연결	index CXR local_path 와 patient/visit 가 정확히 연결되는가?	☐ Go ☐ 수정 ☐ No-Go

촬영 metadata	AP/PA 및 촬영 위치를 shortcut 민감도 분석에 사용할 수 있는가?	☐ Go ☐ 수정 ☐ No-Go
Compute	RAD-DINO feature 를 사전 추출하여 저장할 GPU/시간이 있는가?	☐ Go ☐ 수정 ☐ No-Go

8. Proposed Analysis Workflow

1) Cohort construction: 성인, 비-ICU index CXR, patient-level episode

2) Patient-level Train / Validation / Test split

3) Train clinical data preprocessing + data-driven phenotype discovery

4) Validation/Test 를 Train centroid 에 배정

5) Train 에서 Model A (Clinical) 및 Model B (Clinical+CXR) 학습

6) Test 전체 성능 및 phenotype 별 paired performance 비교

7) Calibration, robustness, shortcut 및 error analysis 후 제한적 해석

9. Literature Search Scope and Limitations

표적 문헌 탐색은 PubMed/PMC, Nature Portfolio 및 출판사 페이지를 중심으로 2026-07-23 에 수행했다. 검색 개념은 (1) ICU transfer/clinical deterioration prediction, (2) chest radiograph + structured EHR multimodal prognosis, (3) data-driven clinical phenotype/clustering, (4) RAD-DINO 였다. 이는 체계적 문헌고찰이 아니며, 검색어·색인·접근성에 따라 누락 가능성이 있다. 따라서 novelty 주장은 “정확히 동일한 연구가 없다”가 아니라 “본 표적 탐색에서 임상정보 기반 phenotype 별 CXR incremental value 를 직접 평가한 선행연구를 확인하지 못했다”로 제한한다.

10. References

- Churpek MM, Yuen TC, Winslow C, Meltzer DO, Kattan MW, Edelson DP. Using electronic health record data to develop and validate a prediction model for adverse outcomes in the wards. Crit Care Med. 2014;42(4):841-848. doi:10.1097/CCM.0000000000000038.
- Edelson DP, Churpek MM, Carey KA, et al. Early Warning Scores With and Without Artificial Intelligence. JAMA Netw Open. 2024;7(10):e2438986. doi:10.1001/jamanetworkopen.2024.38986.
- Cho KJ, Kim JS, Lee DH, et al. Prospective, multicenter validation of the deep learning-based cardiac arrest risk management system for predicting in-hospital cardiac arrest or unplanned intensive care unit transfer in patients admitted to general wards. Crit Care. 2023;27. PMID:37670324.
- Cheng FY, Joshi H, Tandon P, et al. Using Machine Learning to Predict ICU Transfer in Hospitalized COVID-19 Patients. J Clin Med. 2020;9(6):1668. doi:10.3390/jcm9061668.
- Lin J, Yang J, Yin M, et al. Development and Validation of Multimodal Models to Predict the 30-Day Mortality of ICU Patients Based on Clinical Parameters and Chest X-Rays. J Imaging Inform Med. 2024;37(4):1312-1322. doi:10.1007/s10278-024-01066-1.

6. Cheng J, Sollee J, Hsieh C, et al. COVID-19 mortality prediction in the intensive care unit with deep learning based on longitudinal chest X-rays and clinical data. *Eur Radiol*. 2022;32:4446-4456. doi:10.1007/s00330-022-08588-8.
7. Li D, Xing W, Zhao J, Shi C, Wang F. Multimodal deep learning for predicting in-hospital mortality in heart failure patients using longitudinal chest X-rays and electronic health records. *Int J Cardiovasc Imaging*. 2025;41(3):427-440. doi:10.1007/s10554-025-03322-z.
8. Hurley NC, Haimovich AD, Taylor RA, Mortazavi BJ. Visualization of emergency department clinical data for interpretable patient phenotyping. *Smart Health*. 2022;25:100285. doi:10.1016/j.smhl.2022.100285.
9. Pérez-García F, Sharma H, Bond-Taylor S, et al. Exploring scalable medical image encoders beyond text supervision. *Nat Mach Intell*. 2025;7:119-130. doi:10.1038/s42256-024-00965-w.
10. Boulitsakis Logothetis S, Green D, Holland M, Al Moubayed N. Predicting acute clinical deterioration with interpretable machine learning to support emergency care decision making. *Sci Rep*. 2023;13:13563. doi:10.1038/s41598-023-40661-0.

11. Final Positioning Statement for Presentation

기존 연구가 임상정보와 CXR를 결합했을 때의 전체 평균 성능 향상에 집중했다면, 본 연구는 영상과 outcome을 사용하지 않은 초기 임상정보 기반 phenotype을 먼저 도출한 뒤, 각 phenotype에서 CXR-derived feature의 추가 예측 가치가 얼마나 다른지를 평가한다. 본 연구의 목적은 CXR 검사 필요성을 결정하는 것이 아니라, CXR 기반 예측 AI가 특히 유용할 수 있는 환자 유형과 그 한계를 탐색하는 것이다.